

MODELIZACIÓN ARIMA DE LA PRODUCCIÓN DE COCHES HONDA EN JAPÓN



Estadística predictiva

Julia Guerrero y Andrea Millán
Grupo 303

ÍNDICE

1. SERIE DE DATOS OBJETO DE ESTUDIO..... 2
2. TRANSFORMACIÓN ESTACIONARIA DE LA SERIE..... 3
3. IDENTIFICACIÓN MODELO ARIMA CON FAC Y FACP..... 7
4. ESTIMACIÓN DEL MODELO ARIMA..... 8
5. VALIDACIÓN DEL MODELO Y ANÁLISIS DE LOS RESIDUOS..... 10
6. ANÁLISIS DE INTERVENCIÓN Y HOMOGENEIZACIÓN..... 12
7. VALIDACIÓN DEL MODELO DEFINITIVO..... 17
8. PREDICCIONES DEL MODELO DEFINITIVO..... 20
ANEXO 1. DATOS ORIGINALES DE LA SERIE..... 21

1. SERIE DE DATOS OBJETO DE ESTUDIO

La serie de datos utilizada para este trabajo corresponde a la **producción mensual de vehículos de Honda en Japón** en el periodo de **2013-2023**, la cual ha sido obtenida en la página oficial de Honda. Esta base de datos recoge el número de unidades producidas cada mes, por lo que refleja la evolución general de la actividad de la empresa. En ella podremos observar patrones y tendencias, y además fijarnos en fases relevantes durante el periodo, como la pandemia de COVID-19.

La siguiente tabla muestra una parte de la base de datos de la cual obtuvimos los datos de la producción en Japón.

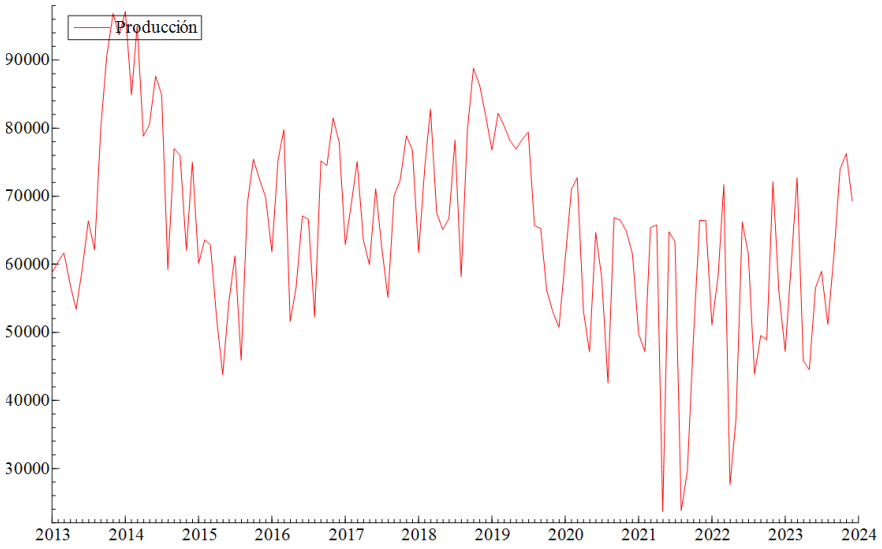
Automobile Production Data

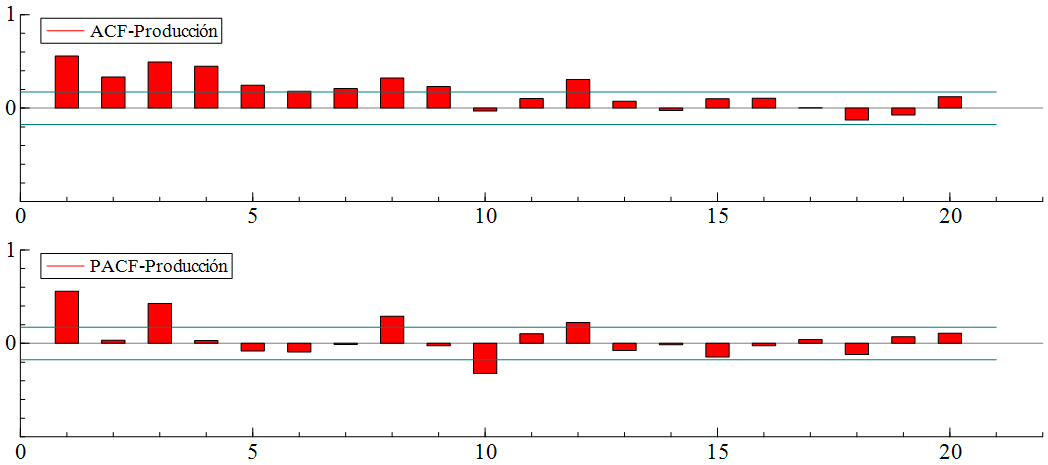
2013	Jan.	Feb.	Mar.	Apr.	May	Jun.	Jul.	Aug.	Sep.	Oct.	Nov.	Dec.
Japan*1	**58.772**	**60.392**	**61.666**	**57.058**	**53.400**	**59.427**	**66.368**	**62.129**	**80.206**	**90.707**	**96.835**	**93.690**
Outside of Japan*2	**284.036**	**267.906**	**295.771**	**297.657**	**294.282**	**280.454**	**272.565**	**277.801**	**302.551**	**328.517**	**301.392**	**254.798**
North America*3	150.666	154.840	150.823	160.764	155.507	141.229	127.739	161.057	147.010	173.155	145.605	112.818
(USA)	107.061	116.519	110.274	118.306	114.403	100.327	93.262	121.208	108.751	129.157	105.835	84.814
Europe	18.983	16.642	11.690	7.281	7.452	9.200	12.003	5.752	12.648	13.398	14.544	10.501
Asia	101.442	82.713	119.051	115.784	116.857	116.041	122.180	95.978	127.567	126.828	128.990	120.740
(China)	52.005	33.435	65.659	64.920	59.268	62.144	67.667	57.983	75.361	79.365	85.644	84.710
Others	12.945	13.711	14.207	13.828	14.466	13.984	10.643	15.014	15.326	15.136	12.253	10.739
Worldwide Total	**342.808**	**328.298**	**357.437**	**354.715**	**347.682**	**339.881**	**338.933**	**339.930**	**382.757**	**419.224**	**398.227**	**348.488**
2014	**Jan.**	**Feb.**	**Mar.**	**Apr.**	**May**	**Jun.**	**Jul.**	**Aug.**	**Sep.**	**Oct.**	**Nov.**	**Dec.**
Japan*1	**97.145**	**84.883**	**95.031**	**78.809**	**80.500**	**87.639**	**84.898**	**59.232**	**76.997**	**75.994**	**62.044**	**75.007**
Outside of Japan*2	**281.672**	**267.941**	**306.576**	**305.602**	**299.966**	**301.742**	**278.599**	**284.310**	**313.270**	**326.633**	**309.215**	**280.064**
North America*3	144.844	148.763	158.655	154.406	151.119	143.663	129.994	161.250	163.676	178.577	139.829	132.348
(USA)	106.106	109.837	113.780	112.564	106.869	100.869	89.020	114.609	113.607	123.212	88.844	89.587
Europe	13.914	14.045	12.887	12.115	7.447	8.973	10.036	4.059	8.489	6.675	11.112	10.243
Asia	110.477	92.982	122.820	126.704	130.515	137.811	128.593	105.406	126.861	126.978	145.376	128.051
(China)	71.522	49.106	72.793	78.624	79.245	82.268	77.272	51.780	67.115	67.542	87.741	71.065
Others	12.437	12.151	12.214	12.377	10.885	11.295	9.976	13.595	14.244	14.403	12.898	9.422
Worldwide Total	**378.817**	**352.824**	**401.607**	**384.411**	**380.466**	**389.381**	**363.497**	**343.542**	**390.267**	**402.627**	**371.259**	**355.071**
2015	**Jan.**	**Feb.**	**Mar.**	**Apr.**	**May**	**Jun.**	**Jul.**	**Aug.**	**Sep.**	**Oct.**	**Nov.**	**Dec.**
Japan*1	**60.130**	**63.591**	**62.841**	**51.944**	**43.773**	**54.473**	**61.244**	**45.897**	**68.897**	**75.448**	**72.416**	**69.839**
Outside of Japan*2	**303.025**	**242.516**	**336.074**	**327.108**	**312.159**	**340.174**	**328.103**	**312.385**	**325.919**	**338.329**	**337.890**	**309.663**
North America*3	157.642	122.627	174.605	162.640	159.175	158.334	155.707	163.543	162.972	163.445	148.759	133.042
(USA)	107.303	83.897	123.599	113.356	110.284	108.315	107.521	112.664	111.729	110.869	93.896	86.291
Europe	11.898	10.845	12.709	11.380	7.348	10.912	12.661	5.046	10.928	8.841	9.080	7.249
Asia	120.560	96.535	134.030	138.623	130.570	155.546	147.572	128.704	135.580	150.317	164.315	158.209
(China)	60.891	39.211	74.203	79.762	75.144	90.932	92.771	74.261	74.633	89.094	104.836	105.175
Others	12.925	12.509	14.730	14.465	15.066	15.382	12.163	15.092	16.439	15.726	15.736	11.163
Worldwide Total	**363.155**	**306.107**	**398.915**	**379.052**	**355.932**	**394.647**	**389.347**	**358.282**	**394.816**	**413.777**	**410.306**	**379.502**
2016	**Jan.**	**Feb.**	**Mar.**	**Apr.**	**May**	**Jun.**	**Jul.**	**Aug.**	**Sep.**	**Oct.**	**Nov.**	**Dec.**
Japan*1	**61.810**	**75.348**	**79.810**	**51.581**	**56.652**	**67.113**	**66.579**	**52.215**	**75.186**	**74.490**	**81.519**	**77.923**
Outside of Japan*2	**342.449**	**321.122**	**375.552**	**352.161**	**341.423**	**358.190**	**305.843**	**351.272**	**374.405**	**347.653**	**377.303**	**331.664**
North America*3	162.340	175.435	173.683	169.843	169.530	176.287	123.848	182.805	168.013	168.075	158.438	127.899
(USA)	105.838	117.678	115.010	110.962	108.351	115.245	81.817	122.734	109.960	110.039	102.566	89.852
Europe	10.878	8.271	12.099	9.866	10.376	10.720	11.933	6.705	13.062	15.013	13.950	11.002
Asia	157.078	125.256	175.532	160.198	149.040	160.142	165.235	147.549	180.064	150.702	189.853	180.233
(China)	95.798	65.130	109.172	94.199	85.523	94.934	111.810	82.266	114.955	94.053	132.401	129.159
Others	12.153	12.160	14.238	12.254	12.477	11.041	4.827	14.213	13.266	13.863	15.062	12.530
Worldwide Total	**404.259**	**396.470**	**455.362**	**403.742**	**398.075**	**425.303**	**372.422**	**403.487**	**449.591**	**422.143**	**458.822**	**409.587**
2017	**Jan.**	**Feb.**	**Mar.**	**Apr.**	**May**	**Jun.**	**Jul.**	**Aug.**	**Sep.**	**Oct.**	**Nov.**	**Dec.**
Japan*1	**62.889**	**69.126**	**75.104**	**63.527**	**59.944**	**71.094**	**62.596**	**55.123**	**70.094**	**72.366**	**78.879**	**76.758**

2. TRANSFORMACIÓN ESTACIONARIA DE LA SERIE

Para poder estimar un modelo ARIMA a la serie de tiempo de la producción de coches Honda en Japón, es fundamental que la serie sea **estacionaria.**

La representación gráfica de la serie original de Producción muestra una tendencia y una varianza que no parecen ser constantes. A simple vista podemos decir que la serie no parece estacionaria.
Para confirmar esta falta de estacionariedad se examinó la función de autocorrelación **(FAC)** y la función de autocorrelación parcial **(FACP)** de la serie original.





La FAC de la serie de producción presenta un **lento decaimiento**, lo cual es una clara indicación de no estacionariedad en media.

Además, para concluir que la serie no es estacionaria realizamos las Pruebas de Raíz Unitaria, tanto incluyendo la constante y tendencia como solo con constante.

PRUEBA RAÍZ UNITARIA

Comprobamos que nuestra serie no es estacionaria

```
Producción: ADF tests (T=128, Constant+Trend; 5%=-3.45 1%=-4.03)
D-lag    t-adf      beta Y_1    sigma   t-DY_lag  t-prob       AIC  F-prob
  3     -3.282       0.660201.084e+04   -0.08367  0.9335     18.63
  2     -3.474*      0.657651.079e+04     -4.683  0.0000     18.61  0.9335
  1     -6.025**     0.436561.167e+04     0.3859  0.7002     18.76  0.0000
  0     -6.868**     0.455541.163e+04                        18.75  0.0002

Unit-root tests
The dataset is: C:\Users\Julia\Desktop\DATOS PRODUCCIÓN HONDA JAPON.xlsx
The sample is: 2013-05-01 - 2023-12-01 (132 observations and 1 variables)

Producción: ADF tests (T=128, Constant; 5%=-2.88 1%=-3.48)
D-lag    t-adf      beta Y_1    sigma   t-DY_lag  t-prob       AIC  F-prob
  3     -2.706       0.764701.094e+04    -0.3744  0.7088     18.64
  2     -2.903*      0.756531.090e+04     -5.308  0.0000     18.62  0.7088
  1     -5.089**     0.571651.203e+04    -0.3921  0.6956     18.81  0.0000
  0     -6.004**     0.556061.199e+04                        18.80  0.0000
```

Hipótesis Nula: (H_0): La serie tiene una raíz unitaria (p=1), es decir, **no es estacionaria.**
Hipótesis Alternativa: (H_1): La serie o tiene una raíz unitaria (p<1), es decir, **es estacionaria.**

$$|\tau| < |DF| : \text{no puedo rechazar } H_0$$

Al comparar los valores |-3,282| < |-3,45|. Dado que el valor absoluto del estadístico prueba (t) es menor que el valor absoluto del valor crítico de Dickey-Fuller (DF 5%, **no se rechaza la Hipótesis Nula (H_0).** Esto confirma que la serie original de Producción tiene una raíz unitaria y, por lo tanto , **no es estacionaria en media.**

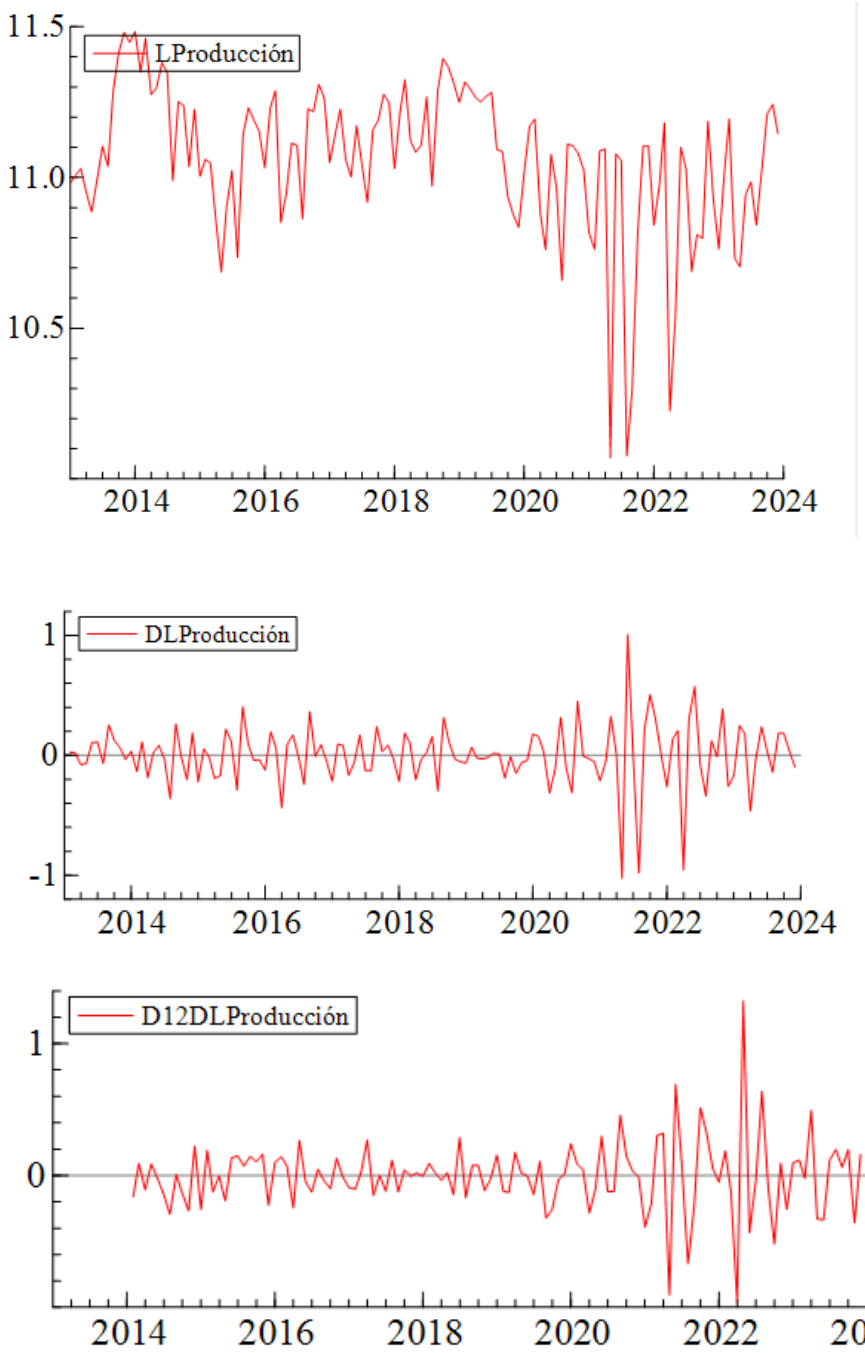
Aplicación de diferencias

Dado que la serie no es estacionaria, se aplican diferencias para estabilizar la serie. Seguimos el siguiente orden:

1. Logarítmica (LProducción)
2. Regular (DLProducción)
3. Estacional (D12DLProducción)

Las representaciones gráficas de estas transformaciones se muestran a continuación, donde se observa como la serie se va haciendo estacionaria.

Diferencias



Para obtener una serie estacionaria, se comenzó aplicando una Diferencia logarítmica LProducción para estabilizar la varianza, seguida de una Diferencia regular para eliminar la tendencia, resultando en la serie DLProducción. Seguidamente se aplicó la diferencia estacional, D12DLProducción.

PRUEBA RAÍZ UNITARIA

D12DL

```
D12DLProducción: ADF tests (T=115, Constant+Trend; 5%=-3.45 1%=-4.04)
D-lag    t-adf      beta Y_1    sigma   t-DY_lag  t-prob       AIC  F-prob
  3     -6.844**    -0.97784   0.2484     0.6922  0.4903    -2.735
  2     -8.152**    -0.85505   0.2478    0.07910  0.9371    -2.748  0.4903
  1     -12.76**    -0.84117   0.2467      4.261  0.0000    -2.765  0.7850
  0     -15.03**    -0.33790   0.2649                        -2.631  0.0007
```

DL

```
DLProducción: ADF tests (T=115, Constant+Trend; 5%=-3.45 1%=-4.04)
D-lag    t-adf      beta Y_1    sigma   t-DY_lag  t-prob       AIC  F-prob
  3     -8.013**     -1.5458   0.2109     0.9755  0.3315    -3.062
  2     -10.33**     -1.3273   0.2108      1.626  0.1068    -3.071  0.3315
  1     -16.62**     -1.0179   0.2124      7.793  0.0000    -3.064  0.1707
  0     -13.89**    -0.26576   0.2630                        -2.645  0.0000
```

Aunque ambas series tras realizar la prueba de raíz unitaria son estacionarias, a simple vista el **gráfico de DLProducción** muestra fluctuaciones menos erráticas y una mayor consistencia en la dispersión a lo largo del tiempo, lo que nos indica que aplicando dos diferencias el **modelo es más estacionario**. Sin embargo, esto lo comprobaremos más tarde al estimar el modelo

Hipótesis Nula: (H_0): La serie tiene una raíz unitaria (p=1), es decir, **no es estacionaria.**
Hipótesis Alternativa: (H_1): La serie o tiene una raíz unitaria (p<1), es decir, **es estacionaria.**

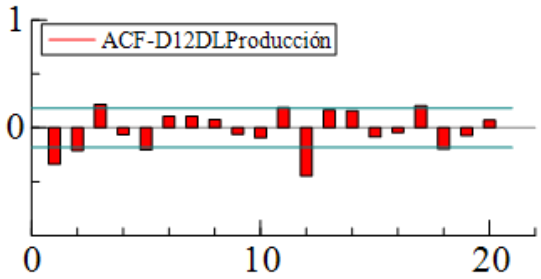
Al comparar los valores: |-8.013| > |-3.45|, es decir, 8.013 > 3.45. Dado que el valor absoluto del estadístico de prueba (t) es mayor que el valor absoluto del valor crítico de Dickey-Fuller (DF5%), **se rechaza la Hipótesis Nula**. Esto confirma que la serie DLProducción no tiene una raíz unitaria y, por lo tanto, **es estacionaria en media.**

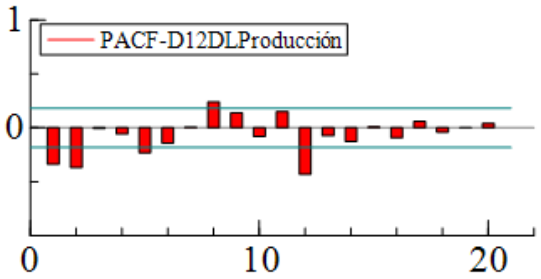
3. IDENTIFICACIÓN MODELO ARIMA CON FAC Y FACP

Una vez obtenidas las series estacionarias mediante las transformaciones aplicadas, el siguiente paso consiste en identificar la estructura ARIMA más adecuada. Para ello, hemos analizado la FAC y la FACP de las dos series obtenidas, tanto la que hemos obtenido con aplicando tres diferencias, como la de dos diferencias.

En el análisis de la **D12DLProducción (tres diferencias)**, la **FAC** muestra valores pequeños y sin un patrón claro, mientras que la **FACP** también presenta valores sin un comportamiento sistemático. Esta conducta indica que la serie ya está suficientemente trabajada, o que podría haber una sobre diferenciación, ya que no se observa ninguna estructura marcada que muestre la identificación del modelo.

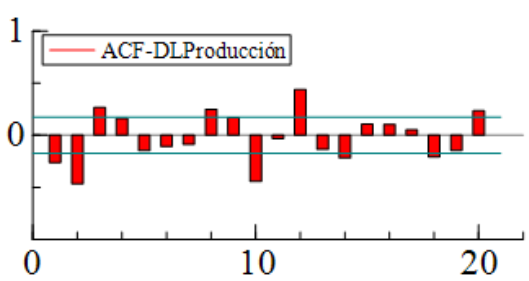
Por tanto, en este caso, la ausencia de comportamientos significativos dificulta la identificación de las órdenes de AR y MA.

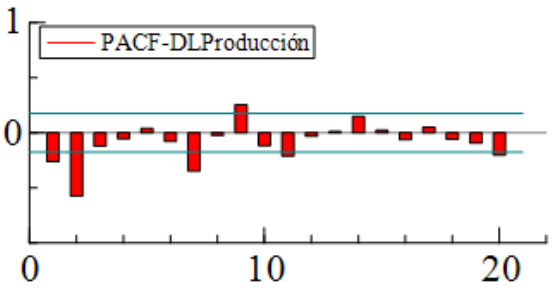




En la serie **DLProducción (dos diferencias)**, la **FAC** los primeros valores se muestran con un comportamiento significativo. Mientras que la **FACP** también presenta dos picos destacados al inicio, lo que permite identificar posibles términos autorregresivos o de medias móviles.

Esta serie tiene una estructura más marcada lo que facilita mucho más la identificación del modelo ARIMA.





En conclusión, tras analizar la FAC y FACP de ambas series, podemos ver que la serie tras aplicar dos diferencias es más apropiada para definir el modelo ARIMA.

4. ESTIMACIÓN DEL MODELO ARIMA

Tras aplicar las diferencias y conseguir hacer estacionaria la serie hay que identificar el modelo ARIMA. Sin embargo, a simple vista con la FAC y FACP no podemos llegar a estimar el modelo. Es por ello, que hemos utilizado Oxmetrics como herramienta para estimar los componentes del modelo ARIMA.

Primero probamos a estimar el modelo con la función automática que te habilita el programa. Oxmetrics nos dio la siguiente salida donde nos indicaba que el modelo es **ARIMA (3,0,0)(0,1,1)$_{12}$**. Este modelo se trata de un AR(3) con un MA(1) estacional con una diferencia estacional.

```
ARIMA Model:  (3 0 0)(0 1 1)
  Seasonal differences:    1
                                          Standard
Parameter                   Estimate        Errors
-----------------------------------------------------
Nonseasonal AR
  Lag  1                     .4644          .07899
  Lag  2                    -.0844          .08842
  Lag  3                     .3379          .08028

Seasonal MA
  Lag 12                     .9206          .06432

Variance                    .27652E-01
SE of Var                   .35698E-02
-----------------------------------------------------

Likelihood Statistics
-------------------------------------------------------------------
Number of observations (nobs)                              132
Effective number of observations (nefobs)                  120
Number of parameters estimated (np)                          6
Log likelihood                                         34.5425
Transformation Adjustment                            -1326.0254
Adjusted Log likelihood (L)                          -1291.4829
AIC                                                   2594.9658
AICC (F-corrected-AIC)                                2595.7091
Hannan Quinn                                          2601.7578
BIC                                                   2611.6907
-------------------------------------------------------------------
```

Sin embargo, podemos decir que este modelo no es el definitivo por varias razones. Al evaluar los coeficientes obtenemos que el **segundo coeficiente de la parte autorregresiva** no cumple con la validación de los coeficientes al dividir la estimación del parámetro y el error estándar.
Además, el modelo automático no incluye la diferencia regular que hemos aplicado anteriormente y si que incluye la diferencia estacional. La cuál habíamos dicho que debíamos eliminar ya que a simple vista la representación de la serie sin a simple vista era menos estacionaria que aplicando únicamente las dos primeras diferencias.

Por lo tanto, acabamos modificando **manualmente** nuestro modelo ARIMA. Debido a que el segundo coeficiente de la parte autorregresiva era el coeficiente no válido, pasamos de un AR(3) a un AR (2). Además, también incluimos la **diferencia regular y la logarítmica**. Finalmente el modelo propuesto fue **ARIMA (2,1,0) $(0,0,1)_{12}$**.

```
MODEL DEFINITION for Producción
Transformation:      Log(y)
ARIMA Model:  (2 1 0)(0 0 1)
regARIMA Model Span: 2013.Jan to 2023.Dec
```

```
ARIMA Model:  (2 1 0)(0 0 1)
  Nonseasonal differences: 1
                                          Standard
Parameter                  Estimate         Errors
-----------------------------------------------------
Nonseasonal AR
  Lag  1                     -.4193          .07417
  Lag  2                     -.5154          .07672

Seasonal MA
  Lag 12                     -.2190          .08712

Variance                      .38182E-01
SE of Var                     .47177E-02
-----------------------------------------------------

Likelihood Statistics
---------------------------------------------------------------------
Number of observations (nobs)                                   132
Effective number of observations (nefobs)                       131
Number of parameters estimated (np)                               4
Log likelihood                                              27.3672
Transformation Adjustment                                -1448.6696
Adjusted Log likelihood (L)                              -1421.3024
AIC                                                       2850.6047
AICC (F-corrected-AIC)                                    2850.9222
Hannan Quinn                                              2855.2780
BIC                                                       2862.1055
---------------------------------------------------------------------
```

5. VALIDACIÓN DEL MODELO Y ANÁLISIS DE LOS RESIDUOS

A continuación, tras haber modificado manualmente el modelo automático proporcionado por Oxmetrics, ya que resultó no ser el modelo definitivo al no cumplir con la evaluación de los coeficientes, procedemos a realizar la validación del siguiente modelo propuesto en el apartado anterior: **ARIMA (2,1,0) $(0,0,1)_{12}$**.

En primer lugar, para la validación del modelo, realizaremos un **análisis de los coeficientes estimados**. Para ello, tendremos que calcular el t-valor de cada uno de ellos:

AR 1→ -0,9143 / 0,07417 = -12,327
AR 2→ -0,5154 / 0,07672 = -6,718

MA 1 $_{12}$ → -0,2190 / 0,08712 = -2,514

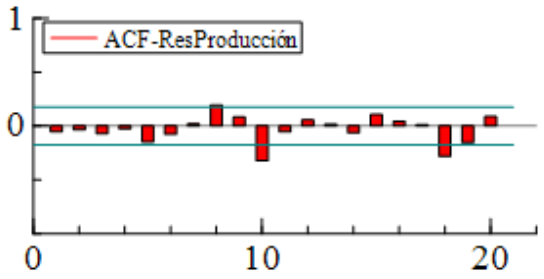
Para ver si los coeficientes estimados son buenos, tomamos lo siguiente como regla de decisión:

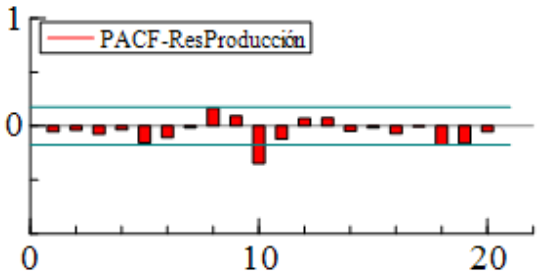
Hipótesis Nula: (H_0): Los coeficientes estimados no son válidos
Hipótesis Alternativa: (H_1): Los coeficiente estimados son válidos

- |T-value| > 1,96 → Rechazamos $\mathbf{H_0}$. El coeficiente estimado es válido
- |T-value| < 1,96 → No rechazamos $\mathbf{H_0}$. El coeficiente estimado no es válido

Como podemos ver, todos los t-value calculados en valor absoluto son mayores que 1,96, por tanto, rechazamos la hipótesis nula y aceptamos $\mathbf{H_1}$, siendo **válidos los coeficientes estimados.**

El siguiente paso es hacer el **análisis de los residuos**. Para ello, primero tenemos que examinar la FAC y FACP con el objetivo de comprobar si hay retardos que se salen de las bandas de significación. Como podemos observar en las gráficas, la mayoría de los retardos se mantienen dentro de las bandas, a excepción de dos retardos en la FAC y uno en la FACP, por tanto procedemos a aplicar las dos siguientes pruebas:





- **Test de Portmanteau**

El test de Portmanteau consiste en comprobar si es un ruido blanco, y para ello nos basaremos en estas dos hipótesis:

Hipótesis Nula: (H_0): Los residuos son Ruido Blanco
Hipótesis Alternativa: (H_1): Los residuos no son Ruido Blanco.

- |p-value| < 0,05→ Rechazamos H_0 . Los residuos no son un ruido blanco
- |p-value| >0,05 → No rechazamos H_0 . Los residuos son un ruido blanco

Para comprobarlo nos fijamos en el corchete [0,0079]**. Según la regla de decisión es menor a 0,05, por tanto, se rechaza H_0 y se acepta H_1, no son ruido blanco.

```
ResProducción: Sample Autocorrelation function (ACF) from lag 1 to 12:
    -0.052892    -0.034529    -0.070361    -0.025801     -0.14522    -0.076059     0.019663
Sample Partial autocorrelation function (PACF):
    -0.052892    -0.037431    -0.074548    -0.035581     -0.15605     -0.10644    -0.013105
Portmanteau(12):  Chi^2(12) =   26.943 [0.0079]**
```

- **Normality Test**

Por último, realizaremos el **test de normalidad de Jarque-Bera** para comprobar si los residuos siguen una distribución normal.

Hipótesis Nula: (H_0): Los residuos siguen una distribución normal.
Hipótesis Alternativa: (H_1): Los residuos no siguen una distribución normal.

- |p-value| < 0,05→ Rechazamos H_0 . Los residuos no siguen una normal
- |p-value| >0,05 → No rechazamos H_0 . Los residuos siguen una normal

En este caso p-value es menor que 0,05, por tanto los residuos no siguen una normal. Esto se debe a que la anomalía tiene un gran efecto en la serie, por tanto, este modelo no es válido.

```
Normality tests and descriptive statistics
The dataset is: C:\Users\Julia\Desktop\DATOS PRODUCCIÓN HONDA JAPON.xlsx
The sample is: 2013-05-01 - 2023-12-01 (128 observations and 1 variables)

Normality test for ResProducción
Observations             128
Mean               0.0029078
Std.Devn.            0.19729
Skewness            -0.75051
Excess Kurtosis       3.8188
Minimum             -0.83612
Maximum              0.57145
Median            -0.0012794
Madn                 0.16233
Asymptotic test:  Chi^2(2)  =   89.795 [0.0000]**
Normality test:   Chi^2(2)  =   32.408 [0.0000]**
```

6. ANÁLISIS DE INTERVENCIÓN Y HOMOGENEIZACIÓN

Una vez evaluados los coeficientes y residuos del modelo propuesto, el siguiente paso consiste en **analizar los outliers**, que como hemos podido comprobar en el test de normalidad, hay presencia de anomalías, y queremos ver si estas son significativas o no.

En este caso nos encontramos con dos tipos de anomalías: impulso (AO) y tendencia (TC). Para verificar si son significativas nos fijamos en el **t-value** de cada anomalía:

AO2021.May → |t-value| = |6,60| > 1,96, este impulso es significativo.
TC2021.Aug → |t-value| = |5,93| > 1,96, esta tendencia es significativa.
AO2022.Apr → |t-value| = |5,14| > 1,96, este impulso es significativo.

Como hemos podido comprobar, todos los outliers son significativos.

```
MODEL ESTIMATION/EVALUATION
Estimation converged in   10 ARMA iterations,   69 function evaluations.

Regression Model
---------------------------------------------------------------------
                            Parameter        Standard
  Variable                   Estimate           Error      t-value
---------------------------------------------------------------------
  Automatically Identified Outliers
    AO2021.May                -.7813          .11845        -6.60
    TC2021.Aug                -.8049          .13577        -5.93
    AO2022.Apr                -.5818          .11314        -5.14
---------------------------------------------------------------------
```

TRADING DAY EFFECT

Al aplicar el **trading day effect**, si nos fijamos en el p-value podemos ver que es mayor a 0,05, lo que significa que el efecto es estadísticamente significativo. Esto indica que, en conjunto, los días de lunes a viernes tienen un impacto relevante en la serie.
Sin embargo, al analizar los **t-values de cada día de la semana** y lo comparamos con el valor de decisión 1,96, observamos que ninguno supera este valor, lo que indica que ningún día es significativo por separado.
En términos generales el efecto día de la semana es significativo, pero realmente no hay ningún día en concreto que tenga un comportamiento atípico.

Regression Model

Variable	Parameter Estimate	Standard Error	t-value
Trading Day			
Mon	-.0133	.02171	-.61
Tue	.0166	.02353	.71
Wed	.0039	.02209	.18
Thu	.0109	.02361	.46
Fri	.0259	.02330	1.11
Sat	-.0397	.02258	-1.76
*Sun (derived)	-.0043	.02378	-.18
Automatically Identified Outliers			
AO2021.May	-.7053	.11686	-6.04
TC2021.Aug	-.8009	.13484	-5.94
AO2022.Apr	-.5613	.11237	-5.00

*For full trading-day and stable seasonal effects, the derived parameter estimate is obtained indirectly as minus the sum of the directly estimated parameters that define the effect.

Chi-squared Tests for Groups of Regressors

Regression Effect	df	Chi-Square	P-Value
Trading Day	6	8.88	.18

WEEKEND EFFECT

Ahora, si nos fijamos en el **efecto fin de semana,** y observamos el t-value, en este caso podemos ver que es mayor que 1,96, por tanto el **weekend effect sí es significativo.** Esto indica que al llegar el fin de semana la producción de coches es diferente que el resto de días de la semana, ya que se comporta distinto.
Además, si nos fijamos en las anomalías que salen, solo se ha detectado **un impulso**, es decir, durante los fines de semana, únicamente en una ocasión se observa un comportamiento atípico.

Outlier	t(AO)	t(LS)	t(TC)
AO2021.Apr	3.48	.88	1.74
AO2021.May	-3.74	-2.77	-2.89
TC2021.Aug	-2.17	-2.31	-3.65

```
Estimation converged in    9 ARMA iterations,   60 function evaluations.

Regression Model
------------------------------------------------------------------------
                             Parameter        Standard
  Variable                    Estimate           Error      t-value
------------------------------------------------------------------------
  Trading Day
    Weekday                     .0118          .00488         2.41
  **Sat/Sun (derived)          -.0294          .01220        -2.41

  Automatically Identified Outliers
    AO2022.Apr                 -.6945          .13051        -5.32
------------------------------------------------------------------------
**For the one coefficient trading-day effect, the derived
  parameter estimate is obtained indirectly as minus -2.5 times
  the directly estimated parameter that defines the effect.
```

LENGTH MONTH

Por último, comprobaremos si el **length of month effect** es significativo, lo que significa que el número de días del mes afecta a la producción. Si nos fijamos en el t-value |0,72| vemos que es menor que 1,96, por tanto, la longitud que tenga cada mes no afecta los valores de la serie.

```
MODEL ESTIMATION/EVALUATION
Estimation converged in    9 ARMA iterations,   70 function evaluations.

Regression Model
------------------------------------------------------------------------
                             Parameter        Standard
  Variable                    Estimate           Error      t-value
------------------------------------------------------------------------
  Length-of-Month              -.0088          .01222         -.72

  Automatically Identified Outliers
    AO2021.May                 -.7681          .11992        -6.41
    TC2021.Aug                 -.8015          .13571        -5.91
    AO2022.Apr                 -.5952          .11435        -5.20
------------------------------------------------------------------------
```

En conclusión, tras analizar las anomalías y los diferentes efectos, hemos visto que tanto el **Trading Day Effect** como **Weekend Effect** tiene un impacto significativo en la serie. Por tanto, para elegir con qué modelo quedarnos debemos volver a analizar la diagnosis del modelo y analizar la bondad del ajuste de cada modelo aplicando cada uno de los efectos por separado.

- Modelo con Trading day effect

En primer lugar analizamos los coeficientes estimados:

AR 1→ -0,2639 / 0,07808 = -3,38
AR 2→ -0,4410 / 0,07948 = -5,549

MA 1 $_{12}$ → -0,2534 / 0,08352 = -3,034

Todos los coeficientes son mayores que 1,96, por tanto rechazamos la hipótesis nula y aceptamos $\mathbf{H_1}$, siendo **válidos los coeficientes estimados.**

ARIMA Model: (2 1 0)(0 0 1)
Nonseasonal differences: 1

Parameter	Estimate	Standard Errors
Nonseasonal AR		
Lag 1	-.2639	.07808
Lag 2	-.4410	.07948
Seasonal MA		
Lag 12	-.2534	.08352
Variance	.21114E-01	
SE of Var	.26088E-02	

Likelihood Statistics

Number of observations (nobs)	132
Effective number of observations (nefobs)	131
Number of parameters estimated (np)	13
Log likelihood	66.1790
Transformation Adjustment	-1448.6696
Adjusted Log likelihood (L)	-1382.4906
AIC	2790.9811
AICC (F-corrected-AIC)	2794.0922
Hannan Quinn	2806.1693
BIC	2828.3587

- Modelo con Weekend effect

AR 1→ -0,3762 / 0,07530 = -4,996
AR 2→ -0,4990 / 0,07672 = -6,504

MA 1 $_{12}$ → -0,3014 / 0,08320 = -3,623

Aplicando el Weekend Effect, los **coeficientes estimados también son válidos**.

ARIMA Model: (2 1 0)(0 0 1)
Nonseasonal differences: 1

Parameter	Estimate	Standard Errors
Nonseasonal AR		
Lag 1	-.3762	.07530
Lag 2	-.4990	.07672
Seasonal MA		
Lag 12	-.3014	.08320
Variance	.30688E-01	
SE of Var	.37918E-02	

Likelihood Statistics

Number of observations (nobs)	132
Effective number of observations (nefobs)	131
Number of parameters estimated (np)	6
Log likelihood	41.4334
Transformation Adjustment	-1448.6696
Adjusted Log likelihood (L)	-1407.2362
AIC	2826.4724
AICC (F-corrected-AIC)	2827.1498
Hannan Quinn	2833.4823
BIC	2843.7236

Ambos modelos cumplen con la prueba de los parámetros. Sin embargo, si nos fijamos en los valores de los parámetros AIC, AICC, Hannan Quinn y BIC, son menores en el modelo con la anomalía **Trading day effect.** Por lo que con esto concluimos que el modelo aplicando la anomalía Trading day effect es el **modelo definitivo**.

Al incorporar el Trading day effect en el modelo definitivo, se corrigen las variaciones derivadas de los días laborables en cada mes. Esto permite eliminar efectos calendario, obtener parámetros más precisos y generar previsiones más fiables.

7. VALIDACIÓN DEL MODELO DEFINITIVO

Como hemos dicho anteriormente el modelo elegido ha sido al que le hemos aplicado la anomalía de **Trading day effect**. Tras elegir este modelo como definitivo ahora tenemos que validar si finalmente los parámetros son válidos y si los residuos tras aplicar las intervenciones y el efecto de las anomalías son un ruido blanco. Ya que como habíamos visto anteriormente, aunque la serie se hubiera convertido en estacionaria, los residuos seguían sin ser un ruido blanco por el efecto que suponía la anomalía en la serie.

CONTRASTES PARÁMETROS ESTIMADOS / DIAGNOSIS DEL MODELO

```
MODEL DEFINITION for Producción
Transformation:      Log(y)
Regression Model     Trading Day
ARIMA Model:  (2 1 0)(0 0 1)
regARIMA Model Span: 2013.Jan to 2023.Dec


ARIMA Model:  (2 1 0)(0 0 1)
  Nonseasonal differences: 1
                                          Standard
Parameter                   Estimate        Errors
-----------------------------------------------------
Nonseasonal AR
  Lag  1                      -.2639         .07808
  Lag  2                      -.4410         .07948

Seasonal MA
  Lag 12                      -.2534         .08352

Variance                     .21114E-01
SE of Var                    .26088E-02
-----------------------------------------------------

Likelihood Statistics
---------------------------------------------------------------------
Number of observations (nobs)                                   132
Effective number of observations (nefobs)                       131
Number of parameters estimated (np)                              13
Log likelihood                                             66.1790
Transformation Adjustment                                -1448.6696
Adjusted Log likelihood (L)                              -1382.4906
AIC                                                       2790.9811
AICC (F-corrected-AIC)                                    2794.0922
Hannan Quinn                                              2806.1693
BIC                                                       2828.3587
---------------------------------------------------------------------
```

El modelo definitivo se trata de un **ARIMA (2,1,0) $(0,0,1)_{12}$**. Tras aplicar el efecto de las anomalías los parámetros cambian, por lo que hay que volver a validar si los coeficientes son válidos. Para ello tenemos que calcular el t-value.

- **t- value: Valor del Estimate / Error estándar**

AR 1→ -0,2639 / 0,07808 = –3,379
AR 2→ -0,4410 / 0,07498 = -5,881

MA 1 $_{12}$ → -0,2534 / 0,08352= -3,034

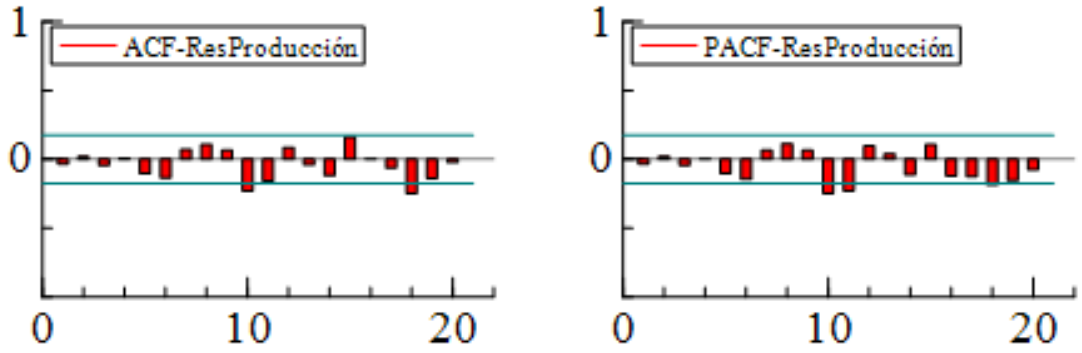
Hipótesis Nula: (H_0): Los coeficientes estimados no son válidos
Hipótesis Alternativa: (H_1): Los coeficiente estimados son válidos

- |T-value| > 1,96 → Rechazamos $\mathbf{H_0}$. El coeficiente estimado es válido
- |T-value| < 1,96 → No rechazamos $\mathbf{H_0}$. El coeficiente estimado no es válido

En este caso, como todos los t-value calculados en valor absoluto son mayores a 1,96, Rechazamos $\mathbf{H_0}$ y podemos confirmar que **los coeficientes estimados del modelo definitivo son válidos**.

ANÁLISIS DE LOS RESIDUOS

Para validar completamente el modelo, se comprueba que los residuos se comportan como Ruido Blanco y sigan una distribución Normal. A simple vista en las gráficas de la FAC y FACP de los residuos podemos ver que los residuos están mayormente dentro de las bandas de significación, esto quiere decir que si son un ruido blanco. Sin embargo, hay que comprobar ambos test para validar esta conclusión.



- **Test de Portmanteau**

Este test evalúa si existe autocorrelación significativa en los residuos.

```
ResProducción: Sample Autocorrelation function (ACF) from lag 1 to 12:
    -0.031947     0.019957    -0.041263     0.0075721     -0.10379     -0.13301     0.071036      0.10837
Sample Partial autocorrelation function (PACF):
    -0.031947     0.018956    -0.040087     0.0046904     -0.10219     -0.14301     0.066818      0.11385
Portmanteau(12):  Chi^2(12) =   19.439 [0.0785]
```

En este caso dado que el p-valor=0,0785 es mayor que 0,05, no se rechaza la $\mathbf{H_0}$. Esto confirma que los residuos del modelo definitivo aplicando las anomalías **se comportan como un Ruido Blanco.**

- **Test de Normalidad de los residuos**

Esta prueba verifica que los residuos siguen una distribución normal.

```
Normality test for ResProducción
Observations              128
Mean                0.0027697
Std.Devn.             0.14626
Skewness            -0.016749
Excess Kurtosis      -0.47686
Minimum              -0.33642
Maximum               0.33416
Median              0.0089308
Madn                  0.14752
Asymptotic test:  Chi^2(2)  =   1.2188 [0.5437]
Normality test:   Chi^2(2)  =  0.74941 [0.6875]
```

Hipótesis Nula: (H_0): Los residuos siguen una distribución normal.
Hipótesis Alternativa: (H_1): Los residuos no siguen una distribución normal.

- |p-value| < 0,05→ Rechazamos $\mathbf{H_0}$. Los residuos no siguen una normal
- |p-value| >0,05 → No rechazamos $\mathbf{H_0}$. Los residuos siguen una normal

En este caso el p-valor= 0,6875 es mayor que 0.05, no se rechaza la $\mathbf{H_0}$. Esto indica que los residuos del modelo **siguen una distribución normal.**

Tras realizar la validación podemos determinar que el modelo **ARIMA (2,1,0) $(0,0,1)_{12}$** con el efecto Trading Day es un modelo válido para la serie de producción de coche Honda en Japón, por lo tanto está listo para ser utilizado en el proceso de predicción.

8. PREDICCIONES DEL MODELO DEFINITIVO

El modelo definitivo genera automáticamente una predicción de 12 meses a partir de diciembre de 2023. La tabla de predicciones muestra las estimaciones puntuales y los intervalos de confianza al 95% para el periodo de enero a diciembre de 2024.

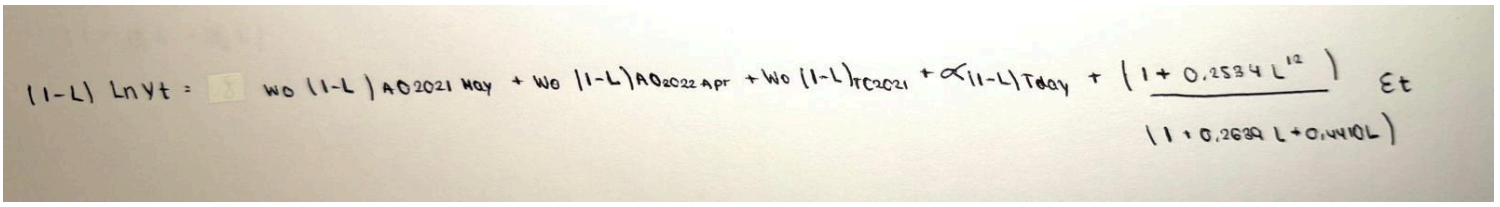
```
FORECASTING
 Origin  2023.Dec
 Number        12

 Confidence intervals with coverage probability ( .95000)
 On the Original Scale
  ---------------------------------------
     Date       Lower  Forecast     Upper
  ---------------------------------------
  2024.Jan   52745.34  70610.91  94527.80
  2024.Feb   52478.83  74965.27 107086.82
  2024.Mar   51372.35  74372.17 107669.19
  2024.Apr   47118.94  71046.04 107123.38
  2024.May   46884.27  73625.57 115619.25
  2024.Jun   42632.77  68861.19 111225.78
  2024.Jul   45412.39  75216.65 124581.53
  2024.Aug   42158.36  71859.84 122486.64
  2024.Sep   42520.52  74476.31 130448.08
  2024.Oct   45588.66  81672.90 146318.45
  2024.Nov   41963.48  77037.39 141426.77
  2024.Dec   41513.97  77858.96 146023.56
  ---------------------------------------
```

Se observa que la predicción para octubre (81.672,90) es la más alta del año, seguida por noviembre y diciembre. Lo cual es coherente teniendo en cuenta los picos estacionales observados en la serie original.
Las predicciones más bajas se encuentran alrededor de abril-mayo y junio-agosto, reflejando la caída de producción después del inicio del año.

Finalmente después de todos los pasos podemos calcular la ecuación estimada del modelo definitivo **ARIMA (2,1,0) (0,0,1)$_{12}$**.
Para ello tenemos que tener en cuenta todas las diferencias que hemos aplicado (diferencia regular y logarítmica), la intervención Trading Day y los outliers de la serie dentro del modelo Trading day.

```
 Automatically Identified Outliers
   AO2021.May                -.7053          .11686        -6.04
   TC2021.Aug                -.8009          .13484        -5.94
   AO2022.Apr                -.5613          .11237        -5.00
-----------------------------------------------------------------
```



ANEXO 1. DATOS ORIGINALES DE LA SERIE

Mes	Producción
ene-13	58.772
feb-13	60.392
mar-13	61.666
abr-13	57.058
may-13	53.400
jun-13	59.427
jul-13	66.368
ago-13	62.129
sep-13	80.206
oct-13	90.707
nov-13	96.835
dic-13	93.690
ene-14	97.145
feb-14	84.883
mar-14	95.031
abr-14	78.809
may-14	80.500
jun-14	87.639
jul-14	84.898
ago-14	59.232
sep-14	76.997
oct-14	75.994

nov-14	62.044
dic-14	75.007
ene-15	60.130
feb-15	63.591
mar-15	62.841
abr-15	51.944
may-15	43.773
jun-15	54.473
jul-15	61.244
ago-15	45.897
sep-15	68.897
oct-15	75.448
nov-15	72.416
dic-15	69.839
ene-16	61.810
feb-16	75.348
mar-16	79.810
abr-16	51.581
may-16	56.652
jun-16	67.113
jul-16	66.579
ago-16	52.215
sep-16	75.186
oct-16	74.490
nov-16	81.519
dic-16	77.923
ene-17	62.889

feb-17	69.126
mar-17	75.104
abr-17	63.527
may-17	59.944
jun-17	71.094
jul-17	62.596
ago-17	55.123
sep-17	70.094
oct-17	72.366
nov-17	78.879
dic-17	76.758
ene-18	61.693
feb-18	74.353
mar-18	82.789
abr-18	67.540
may-18	65.100
jun-18	66.707
jul-18	78.231
ago-18	58.165
sep-18	79.748
oct-18	88.818
nov-18	86.283
dic-18	81.821
ene-19	76.776
feb-19	82.187
mar-19	80.461
abr-19	78.178

may-19	76.916
jun-19	78.355
jul-19	79.415
ago-19	65.674
sep-19	65.259
oct-19	56.183
nov-19	52.928
dic-19	50.724
ene-20	60.657
feb-20	71.006
mar-20	72.696
abr-20	53.114
may-20	47.116
jun-20	64.662
jul-20	58.011
ago-20	42.549
sep-20	66.851
oct-20	66.509
nov-20	64.843
dic-20	61.486
ene-21	49.764
feb-21	47.158
mar-21	65.356
abr-21	65.794
may-21	23.643
jun-21	64.778
jul-21	63.302

ago-21	23.790
sep-21	29.743
oct-21	49.415
nov-21	66.433
dic-21	66.411
ene-22	51.084
feb-22	58.354
mar-22	71.721
abr-22	27.598
may-22	37.285
jun-22	66.223
jul-22	61.568
ago-22	43.827
sep-22	49.524
oct-22	48.907
nov-22	72.129
dic-22	55.753
ene-23	47.193
feb-23	60.572
mar-23	72.759
abr-23	45.833
may-23	44.510
jun-23	56.533
jul-23	58.972
ago-23	51.162
sep-23	61.515
oct-23	73.939

nov-23	76.272
dic-23	69.261